

ΕΡΓΑΣΙΑ ΑΝΑΓΝΩΡΙΣΗΣ ΠΡΟΤΥΠΩΝ

ΜΑΡΚΑΝΤΩΝΗΣ ΑΝΤΩΝΗΣ(22097)

ΑΡΜΑΝΤΟ ΖΙΦΛΑΙ(22222)

ΒΑΣΙΛΗΣ ΦΡΑΓΚΟΥΛΗΣ(22273)

Ο κώδικας εκτελεί ανάλυση δεδομένων, προ επεξεργασία, εκπαίδευση μοντέλων Perceptron και Γραμμικής Παλινδρόμησης, καθώς και αξιολόγηση των αποτελεσμάτων μέσω διασταυρωμένης επικύρωσης.

Βιβλιοθήκες που χρησιμοποιούνται

- pandas για τη διαχείριση δεδομένων
- numpy για αριθμητικούς υπολογισμούς
- matplotlib.pyplot και seaborn για οπτικοποίηση δεδομένων
- sklearn.model_selection για τον διαχωρισμό δεδομένων
- sklearn.preprocessing και sklearn.compose για προ επεξεργασία δεδομένων
- sklearn.pipeline και sklearn.impute για μετασχηματισμούς και διαχείριση ελλιπών δεδομένων
- sklearn.metrics για την αξιολόγηση των μοντέλων

Βήματα Επεξεργασίας και Ανάλυσης

1. Φόρτωση Δεδομένων

Η συνάρτηση `load_data(file_path: str)` φορτώνει το αρχείο `housing.csv`.

2. Δημιουργία Δυναμικού Στόχου

Ορίζεται μια νέα στήλη `target_class`, που παίρνει την τιμή 1 αν η `median_house_value` είναι μεγαλύτερη από τη διάμεσο τιμή, διαφορετικά 0.

3. Καθορισμός Χαρακτηριστικών

Διαχωρίζονται οι αριθμητικές μεταβλητές `numeric_attributes` και οι κατηγορικές μεταβλητές `categorical_attributes`.

4. Προεπεξεργασία Δεδομένων

Δημιουργούνται `pipelines` για την κανονικοποίηση και την αντιμετώπιση ελλιπών τιμών:

- Τα αριθμητικά χαρακτηριστικά συμπληρώνονται με τη διάμεσο και κανονικοποιούνται με `StandardScaler()`.
- Τα κατηγορικά συμπληρώνονται με τη συχνότερη τιμή και κωδικοποιούνται με `OneHotEncoder()`.
- Χρησιμοποιείται `ColumnTransformer` για εφαρμογή των μετασχηματισμών.

5. Οπτικοποίηση Δεδομένων

- Δημιουργείται heatmap για τη συσχέτιση μεταβλητών.
- Δημιουργείται scatter plot για τη σχέση `median_income` και `median_house_value`.

6. Διαχωρισμός Δεδομένων (Stratified Split)

Χρησιμοποιείται `StratifiedShuffleSplit` για διαχωρισμό των δεδομένων σε σύνολα εκπαίδευσης (80%) και δοκιμής (20%), διατηρώντας την αναλογία των κατηγοριών του `target_class`.

7. Υλοποίηση Perceptron

- Αρχικοποιεί βάρη και bias.
- Ενημερώνει τα βάρη χρησιμοποιώντας τον κανόνα εκμάθησης perceptron.
- Υπολογίζει τις προβλέψεις βασισμένες στο γραμμικό συνδυασμό εισόδων.

8. Υλοποίηση Γραμμικής Παλινδρόμησης (Least Squares Regression)

Η κλάση `LeastSquaresRegression` υλοποιεί την μέθοδο ελαχίστων τετραγώνων:

- Χρησιμοποιεί τον τύπο $W = (X^T * X)^{-1} * X^T * y$ για την εύρεση των συντελεστών.
- Χρησιμοποιεί bias term προσθέτοντας μια στήλη με άσσους στα δεδομένα εισόδου.

9. Εκπαίδευση και Αξιολόγηση Μοντέλων

Η συνάρτηση `train_and_evaluate_model`:

- Εκπαιδεύει το μοντέλο.
- Υπολογίζει MSE (Mean Squared Error) και MAE (Mean Absolute Error) για το σύνολο εκπαίδευσης και δοκιμής.
- Εκτελείται για το Perceptron και τη Γραμμική Παλινδρόμηση.

10. Διασταυρωμένη Επικύρωση (Cross-Validation)

Η συνάρτηση `cross_validate_custom`:

- Χρησιμοποιεί `KFold` για 10 φορές επαναλαμβανόμενο διαχωρισμό των δεδομένων.
- Εκπαιδεύει το μοντέλο και υπολογίζει το μέσο όρο του MSE.
- Εφαρμόζεται σε Perceptron και Γραμμική Παλινδρόμηση.